

从矩阵坐标变换到 PCA：一条完整推理链

整理版学习笔记

2026 年 6 月 11 日

这份笔记的目标是把下面这条链条说清楚：

矩阵坐标变换 $\rightarrow$ 投影 $\rightarrow$ 方向方差 $\rightarrow$ 协方差矩阵 $\rightarrow$ 特征向量 $\rightarrow$ PCA $\rightarrow$ 白化.

核心结论是：协方差矩阵的特征向量之所以能表示数据变化的主方向，是因为任意方向上的投影方差都可以写成

$$\text{Var}(u^\top x) = u^\top \Sigma u,$$

而最大化这个量会推出特征方程

$$\Sigma u = \lambda u.$$

目录

1 数据、向量和矩阵：先明确对象

在机器学习中，一个样本通常被表示为一个向量：

$$x = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_d \end{bmatrix} \in \mathbb{R}^d.$$

这里的维度 d 指的是一个样本有多少个特征，不是样本数量。

如果有 n 个样本，每个样本有 d 个特征，就可以组成数据矩阵：

$$X = \begin{bmatrix} - & x_1^\top & - \\ - & x_2^\top & - \\ & \vdots & \\ - & x_n^\top & - \end{bmatrix} \in \mathbb{R}^{n \times d}.$$

其中每一行是一个样本，每一列是一个特征。

符号	形状	含义
x_i	$d \times 1$	第 i 个样本向量
X	$n \times d$	全部样本组成的数据矩阵
n	标量	样本数量
d	标量	每个样本的特征数，也就是维度

后面讨论 PCA 时，我们默认先把数据中心化，即减去均值：

$$x_c = x - \mu, \quad X_c = X - \mathbf{1}\mu^\top.$$

为了简洁，后文很多地方直接把中心化后的 x_c 记作 x 。

2 坐标系变换：为什么是 $U^\top x$?

2.1 新坐标轴组成一个矩阵

假设我们在二维平面里有一组新的单位正交坐标轴：

$$u_1, u_2.$$

把它们作为列向量放在一起：

$$U = \begin{bmatrix} | & | \\ u_1 & u_2 \\ | & | \end{bmatrix}.$$

如果 u_1, u_2 是单位正交的，那么：

$$u_i^\top u_j = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

这等价于：

$$U^\top U = I.$$

因此 U 是正交矩阵，满足：

$$U^{-1} = U^\top.$$

2.2 从新坐标回到旧坐标： $x = Uz$

如果 z 是一个向量在新坐标系下的坐标，例如

$$z = \begin{bmatrix} z_1 \\ z_2 \end{bmatrix},$$

那么它在旧坐标系中的表示是：

$$x = z_1 u_1 + z_2 u_2 = Uz.$$

所以 U 的作用是：

新坐标 $z \rightarrow$ 旧坐标 x .

2.3 从旧坐标变到新坐标： $z = U^\top x$

既然

$$x = Uz,$$

两边左乘 U^{-1} ：

$$U^{-1}x = z.$$

而正交矩阵有 $U^{-1} = U^\top$ ，所以：

$$z = U^\top x.$$

这就是为什么坐标变换时经常左乘一个转置矩阵。

从投影角度看更直观。因为


$$U^\top = \begin{bmatrix} - & u_1^\top & - \\ - & u_2^\top & - \end{bmatrix},$$

所以

$$U^\top x = \begin{bmatrix} u_1^\top x \\ u_2^\top x \end{bmatrix}.$$

其中 $u_1^\top x$ 是 x 在新轴 u_1 上的投影长度， $u_2^\top x$ 是 x 在新轴 u_2 上的投影长度。

左乘 $U^\top$ 不是把点移动了，而是把同一个几何向量用新的坐标轴重新描述。条件是 U 的列向量必须是单位正交基。



3 投影到一个方向：方向上的变化怎么定义？

现在给定一个单位方向 u ，即

$$\|u\| = 1.$$

一个中心化样本 x 在方向 u 上的投影是：

$$z = u^\top x.$$

如果所有样本都投影到方向 u 上，就得到一组一维数值：

$$z_1 = u^\top x_1, \quad z_2 = u^\top x_2, \quad \dots, \quad z_n = u^\top x_n.$$

这些投影值的方差就是数据沿方向 u 的变化大小。

也就是说：

某个方向上的变化大小 = 数据投影到该方向后的方差.

4 协方差矩阵：它为什么能描述任意方向上的方差？

中心化后的协方差矩阵定义为：

$$\Sigma = \mathbb{E}[xx^\top].$$

如果用有限样本估计，常见写法是：

$$\Sigma = \frac{1}{n} X_c^\top X_c$$

或用无偏估计：

$$\Sigma = \frac{1}{n-1} X_c^\top X_c.$$

二者只差一个比例因子，不影响主方向。

现在看方向 u 上的投影方差：

$$\text{Var}(u^\top x) = \mathbb{E}[(u^\top x)^2].$$

因为 $u^\top x$ 是标量，所以：

$$(u^\top x)^2 = (u^\top x)(x^\top u) = u^\top x x^\top u.$$

因此：

$$\text{Var}(u^\top x) = \mathbb{E}[u^\top x x^\top u] = u^\top \mathbb{E}[x x^\top] u = u^\top \Sigma u.$$

这是 PCA 的核心公式：

$$\text{Var}(u^\top x) = u^\top \Sigma u.$$

它说明：只要知道协方差矩阵 Σ ，就能计算数据在任意方向 u 上的变化大小。

5 找变化最大的方向：为什么会出现特征向量？

PCA 要找的第一主方向就是让投影方差最大的单位方向：

$$\max_{\|u\|=1} u^\top \Sigma u.$$

这里要求 $\|u\| = 1$ ，是为了避免把方向向量无限放大。如果不限长度， $u^\top \Sigma u$ 可以被人为放大，没有意义。

5.1 用拉格朗日乘子推导

构造拉格朗日函数：

$$\mathcal{L}(u, \lambda) = u^\top \Sigma u - \lambda(u^\top u - 1).$$

对 u 求导并令其为 0：

$$\nabla_u \mathcal{L} = 2\Sigma u - 2\lambda u = 0.$$

于是得到：

$$\Sigma u = \lambda u.$$

这就是特征值方程。

因此，最优方向 u 必须是协方差矩阵 Σ 的特征向量。对应的方向方差为：

$$u^\top \Sigma u = u^\top \lambda u = \lambda u^\top u = \lambda.$$

因为 $\|u\| = 1$ ，所以 $u^\top u = 1$ 。

数学对象	数据分析含义
特征向量 u	数据变化的主方向
特征值 λ	沿这个方向的方差大小
最大特征值对应的特征向量	第一主成分方向
第二大特征值对应的特征向量	第二主成分方向

6 坐标变换和 PCA 的连接

因为协方差矩阵 Σ 是对称矩阵，所以可以正交对角化：

$$\Sigma = U\Lambda U^\top.$$

其中

$$U = \begin{bmatrix} | & | & & | \\ u_1 & u_2 & \cdots & u_d \\ | & | & & | \end{bmatrix}$$

由协方差矩阵的特征向量组成，

$$\Lambda = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_d)$$

由对应特征值组成，并且通常排序为：

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_d \geq 0.$$

把原数据变换到特征向量坐标系：

$$z = U^\top x.$$

新坐标 z 的协方差为：

$$\text{Cov}(z) = \text{Cov}(U^\top x) = U^\top \Sigma U.$$

代入 $\Sigma = U\Lambda U^\top$ ：

$$\text{Cov}(z) = U^\top (U\Lambda U^\top) U = (U^\top U) \Lambda (U^\top U) = \Lambda.$$

所以在 PCA 坐标系下，协方差矩阵变成对角矩阵：

$$\text{Cov}(z) = \begin{bmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_d \end{bmatrix}.$$

这一步说明：PCA 本质上是在寻找一个新的正交坐标系，使得数据在新坐标系下的协方差矩阵变成对角形式。对角线上的数就是各主方向上的方差。

7 PCA 的完整流程

PCA 的标准流程可以写成如下几步。

1. 中心化数据：

$$X_c = X - \mathbf{1}\mu^\top.$$

2. 计算协方差矩阵：

$$\Sigma = \frac{1}{n} X_c^\top X_c.$$

3. 特征分解：

$$\Sigma = U \Lambda U^\top.$$

4. 按特征值从大到小排序：

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_d.$$

5. 选前 k 个主方向：

$$U_k = \begin{bmatrix} | & | & \cdots & | \\ u_1 & u_2 & \cdots & u_k \\ | & | & \cdots & | \end{bmatrix} \in \mathbb{R}^{d \times k}.$$


6. 投影降维：

$$z = U_k^\top (x - \mu).$$

对所有样本：

$$Z = X_c U_k.$$

这里 $Z \in \mathbb{R}^{n \times k}$ ，也就是说原来的 d 维样本被压缩成了 k 维。



8 二维例子： $\begin{bmatrix} 10 & 8 \\ 8 & 10 \end{bmatrix}$

考虑协方差矩阵：

$$\Sigma = \begin{bmatrix} 10 & 8 \\ 8 & 10 \end{bmatrix}.$$

它表示两个特征方差都较大，而且强正相关，因为非对角线元素 $8 > 0$ 。

看方向 $[1, 1]^\top$ ：

$$\Sigma \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 18 \\ 18 \end{bmatrix} = 18 \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

所以 $[1, 1]^\top$ 是特征向量，对应特征值 18。它表示 $x_1 = x_2$ 的右上方向，数据沿这个方向变化最大。

看方向 $[1, -1]^\top$ ：

$$\Sigma \begin{bmatrix} 1 \\ -1 \end{bmatrix} = \begin{bmatrix} 2 \\ -2 \end{bmatrix} = 2 \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

所以 $[1, -1]^\top$ 是特征向量，对应特征值 2。它表示 $x_1 = -x_2$ 的右下方向，数据沿这个方向变化较小。

更规范地写成单位向量：

$$u_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad u_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$


于是 PCA 坐标变换为：

$$z = U^\top x, \quad U = \begin{bmatrix} | & | \\ u_1 & u_2 \\ | & | \end{bmatrix}.$$

变换后，新坐标的协方差是：

$$U^\top \Sigma U = \begin{bmatrix} 18 & 0 \\ 0 & 2 \end{bmatrix}.$$

这表示 PCA 坐标系已经把斜着的椭圆转正了：第一轴方差为 18，第二轴方差为 2。



强正相关的数据云沿 $x_1 = x_2$ 方向拉长

9 白化：在 PCA 坐标系上进一步统一尺度

PCA 只完成了旋转坐标系，使协方差矩阵对角化：

$$z = U^\top (x - \mu), \quad \text{Cov}(z) = \Lambda.$$

如果还想让每个主方向的方差都变成 1，就再除以标准差：

$$y = \Lambda^{-1/2} U^\top (x - \mu).$$

其中

$$\Lambda^{-1/2} = \text{diag} \left(\frac{1}{\sqrt{\lambda_1}}, \frac{1}{\sqrt{\lambda_2}}, \dots, \frac{1}{\sqrt{\lambda_d}} \right).$$

于是

$$\text{Cov}(y) = \Lambda^{-1/2} U^\top \Sigma U \Lambda^{-1/2} = \Lambda^{-1/2} \Lambda \Lambda^{-1/2} = I.$$

这就是白化。

PCA 是把数据云旋转到主方向坐标系；白化是在此基础上再缩放每个主方向，使各方向方差都变成 1。

10 机器学习数据分析中的应用

10.1 降维

如果原始特征维度很高，例如 $d = 768$ ，但前 $k = 50$ 个主成分已经解释了大部分方差，那么可以用：

$$Z = X_c U_k$$

把数据从 768 维降到 50 维。

这可以减少存储和计算，也可能降低噪声。

10.2 可视化

把高维数据投影到前两个主成分：

$$Z = X_c \begin{bmatrix} u_1 & u_2 \end{bmatrix},$$

可以得到二维坐标，用来观察类别是否分开、异常点在哪里、不同标签是否有结构。

10.3 去冗余

如果很多原始特征高度相关，协方差矩阵会有少数较大的特征值和很多较小的特征值。这说明数据主要变化集中在少数方向上，原始特征有冗余。

10.4 改善优化

如果不同方向的方差差别很大，损失曲面可能很狭长，梯度下降会走得很别扭。标准化、PCA、白化可以缓解尺度不均或相关性强的问题，使优化更稳定。

10.5 分析深度特征

如果一个深度模型输出 embedding，例如每个 CT volume 得到一个 768 维特征向量，可以把所有样本特征组成矩阵

$$Z \in \mathbb{R}^{n \times 768}.$$

然后可以分析：

- 前多少个主成分解释了大部分方差；
- 阳性和阴性样本在 PCA 平面上是否分开；
- 不同区域节点特征是否高度相关；
- 模型是否把信息集中在少数方向上。

11 常见误解

误解	更准确的说法
左乘 $U^\top$ 是把点旋转了	对单个向量来说，它是换坐标表示；几何向量本身没变。
PCA 一定提升分类性能	PCA 保留最大方差方向，但最大方差不一定就是最有判别力的方向。
特征值越小越没用	小方差方向常常是噪声，但在某些任务里也可能包含标签相关信息。
白化总是更好	白化会改变特征尺度，有时有利于优化，有时可能放大噪声。
协方差为 0 就完全无关	协方差为 0 只表示无线性相关，仍可能存在非线性关系。

12 最终总结

整条推理链可以压缩成下面几步：

1. 新坐标轴组成正交矩阵 U 。

2. 从旧坐标到新坐标是

$$z = U^\top x.$$

因为 $U^\top x$ 的每个分量都是 x 在对应新轴上的投影。

3. 数据沿方向 u 的变化大小是投影方差：

$$\text{Var}(u^\top x) = u^\top \Sigma u.$$

4. 找变化最大的方向就是解：

$$\max_{\|u\|=1} u^\top \Sigma u.$$

5. 这个优化问题推出特征方程：

$$\Sigma u = \lambda u.$$

6. 所以协方差矩阵的特征向量就是数据变化的主方向，特征值就是沿该方向的方差。

7. PCA 就是把数据投影到前 k 个最大特征值对应的特征向量上：

$$z = U_k^\top (x - \mu), \quad Z = X_c U_k.$$

8. 白化则进一步缩放 PCA 坐标：

$$y = \Lambda^{-1/2} U^\top (x - \mu), \quad \text{Cov}(y) = I.$$

一句话总结：PCA 是一种特殊的坐标系变换。它不是随便换坐标，而是把坐标轴换成协方差矩阵的特征向量，使第一个新坐标轴对应数据变化最大的方向，第二个对应剩余变化最大的方向，以此类推。