

深度线性网络中 W_1 的梯度推导

全程采用“梯度与被求导变量同形状”的统一约定

统一约定：若 x 是列向量，则 $\nabla_x L$ 也是列向量；若 X 是矩阵，则 $\nabla_X L$ 与 X 同形状。对应的微分定义为

$$dL = (\nabla_x L)^T dx, \quad dL = \text{Tr}[(\nabla_X L)^T dX].$$

这套记号避免了“某处把导数写成行向量、某处又把梯度写成同形状矩阵”的混用。

1. 问题设置

只考虑一个训练样本。设

$$x \in \mathbb{R}^{N_1 \times 1}, \quad W_1 \in \mathbb{R}^{N_2 \times N_1}, \quad W_2 \in \mathbb{R}^{N_3 \times N_2}, \quad y \in \mathbb{R}^{N_3 \times 1}.$$

网络输出为

$$\hat{y} = W_2 W_1 x,$$

定义误差向量

$$e = y - W_2 W_1 x.$$

损失函数为

$$L = \frac{1}{2} \|e\|^2 = \frac{1}{2} e^T e.$$

目标是求

$$\boxed{\nabla_{W_1} L}.$$

2. 第一步：求损失的微分

从

$$L = \frac{1}{2} e^T e$$

出发。利用乘积微分法则，

$$d(e^T e) = (de)^T e + e^T de.$$

其中 $(de)^T e$ 是一个 1×1 标量，因此它等于自己的转置：

$$(de)^T e = ((de)^T e)^T = e^T de.$$

于是

$$d(e^T e) = 2e^T de,$$

因此

$$\boxed{dL = e^T de}.$$

这里要特别注意：这并不表示梯度是 e^T 。因为我们统一采用

$$dL = (\nabla_e L)^T de.$$

与 $dL = e^T de$ 比较可得

$$(\nabla_e L)^T = e^T,$$

所以

$$\boxed{\nabla_e L = e}.$$

3. 第二步：求误差 e 的微分

由于

$$e = y - W_2 W_1 x,$$

现在只对 W_1 求梯度，所以把 y 、 W_2 、 x 都视为常量。于是

$$de = d(y - W_2 W_1 x) = -W_2 dW_1 x.$$

即

$$de = -W_2 dW_1 x.$$

把它代入上一节的 $dL = e^T de$ ：

$$dL = e^T (-W_2 dW_1 x),$$

得到

$$dL = -e^T W_2 dW_1 x.$$

4. 第三步：为什么要引入迹

上式右边的维度为

$$(1 \times N_3)(N_3 \times N_2)(N_2 \times N_1)(N_1 \times 1) = 1 \times 1,$$

所以它是一个标量。任何标量 a 都满足

$$a = \text{Tr}(a).$$

因此

$$dL = -\text{Tr}(e^T W_2 dW_1 x).$$

引入迹的目的不是改变数学内容，而是为了利用迹的循环性质：

$$\text{Tr}(ABCD) = \text{Tr}(DABC).$$

因此

$$\text{Tr}(e^T W_2 dW_1 x) = \text{Tr}(x e^T W_2 dW_1).$$

于是

$$dL = -\text{Tr}(x e^T W_2 dW_1).$$

为什么把 dW_1 放到最后？

并不是数学上强制要求它必须在最后，而是因为矩阵梯度的标准微分形式写成

$$dL = \text{Tr}[(\nabla_{W_1} L)^T dW_1].$$

把 dW_1 整理到最后，就能直接读出前面的系数。由于矩阵乘法一般不满足交换律，不能随便交换矩阵次序；这里能够调整位置，是因为使用的是迹的**循环性质**，而不是交换律。

5. 第四步：与梯度定义比较

矩阵梯度的定义为

$$dL = \text{Tr}[(\nabla_{W_1} L)^T dW_1].$$

而我们已经得到

$$dL = \text{Tr}[-x e^T W_2 dW_1].$$

逐项比较可得

$$(\nabla_{W_1} L)^T = -x e^T W_2.$$

两边转置：

$$\nabla_{W_1} L = (-x e^T W_2)^T.$$

利用

$$(ABC)^T = C^T B^T A^T,$$

得到

$$\nabla_{W_1} L = -W_2^T e x^T.$$

再代回

$$e = y - W_2 W_1 x,$$

最终有

$$\nabla_{W_1} L = -W_2^T (y - W_2 W_1 x) x^T.$$

6. 维度检查

$$W_2^T \in \mathbb{R}^{N_2 \times N_3}, \quad e \in \mathbb{R}^{N_3 \times 1}, \quad x^T \in \mathbb{R}^{1 \times N_1}.$$

所以

$$W_2^T e x^T \in (N_2 \times N_3)(N_3 \times 1)(1 \times N_1) = \mathbb{R}^{N_2 \times N_1}.$$

这与

$$W_1 \in \mathbb{R}^{N_2 \times N_1}$$

完全一致，符合“梯度与被求导变量同形状”的约定。

7. 一页式推导链

以后可以把整个过程压缩记成下面这条链：

$$\begin{aligned} L &= \frac{1}{2} e^T e, \\ e &= y - W_2 W_1 x, \\ dL &= e^T de, \\ de &= -W_2 dW_1 x, \\ \Rightarrow dL &= -e^T W_2 dW_1 x, \\ &= -\text{Tr}(e^T W_2 dW_1 x), \\ &= -\text{Tr}(x e^T W_2 dW_1), \\ &= \text{Tr}[(\nabla_{W_1} L)^T dW_1]. \end{aligned}$$

因此

$$(\nabla_{W_1} L)^T = -x e^T W_2,$$

从而

$$\nabla_{W_1} L = -W_2^T e x^T$$

以及

$$\nabla_{W_1} L = -W_2^T (y - W_2 W_1 x) x^T.$$

核心记忆：

- 向量： $dL = (\nabla_x L)^T dx$ 。
- 矩阵： $dL = \text{Tr}[(\nabla_X L)^T dX]$ 。
- 微分表达式里出现的是“梯度的转置”。
- 引入迹只是为了利用循环性质整理矩阵次序。
- 不能把迹的循环性质误解成矩阵乘法满足交换律。