


从 Hoeffding 不等式到 VC 泛化界

二分类样本复杂度推导笔记

2026 年 5 月 26 日

一句话结论：对二分类的 0-1 损失，Hoeffding 不等式先给出固定分类器的集中界；再用 union bound（并合界）推广到有限假设空间；对于无限假设空间，用增长函数 $\Pi_{\mathcal{H}}(n)$ 描述其在有限样本上的有效大小；再用 Sauer-Shelah 引理把增长函数由 VC 维 d 控制，得到 VC 泛化界。



目录

1	先澄清：你图中的公式和“朴素推导”的关系	3
2	问题设定：二分类与 0-1 损失	3
2.1	我们想证明什么？	4
3	第一步：固定一个分类器时，Hoeffding 不等式给出集中界	4
3.1	为什么会出现 ϵ^2 ？	4
4	第二步：有限假设空间，用 union bound 同时控制所有分类器	5
5	第三步：无限假设空间不能直接使用 $ \mathcal{H} $	6

6 第四步：对称化，把真实风险换成两个经验风险之差	6
7 第五步：在 $2n$ 个点上计数，再使用 Hoeffding	7
8 第六步：用 VC 维控制增长函数	8
9 第七步：由 VC 泛化界解出样本复杂度	9
10 第八步：如何理解更简洁的 $O((d + \log(1/\delta))/\epsilon^2)$?	9
11 ERM 的泛化含义：训练误差小为什么能推出真实误差小？	10
12 常见误区总结	11
13 完整推导链条回顾	11
附：经典来源	12

1 先澄清：你图中的公式和“朴素推导”的关系

你前面图里的形式是

$$n = O\left(\frac{d + \log(1/\delta)}{\epsilon^2}\right).$$

这里 d 是 VC 维， ϵ 是允许误差， δ 是失败概率。

需要注意一个技术点：

- **最朴素路线**：Hoeffding 不等式 + union bound + Sauer-Shelah 引理，通常推出

$$n = O\left(\frac{d \log(1/\epsilon) + \log(1/\delta)}{\epsilon^2}\right),$$

也就是会多一个 $\log(1/\epsilon)$ 因子。

- **更精细的 VC 理论**：通过经验过程、Rademacher 复杂度（拉德马赫复杂度，即用随机 ± 1 噪声衡量函数类拟合纯噪声的能力）、packing/covering 等更紧分析，可以去掉这个对数因子，得到最优量级

$$n = O\left(\frac{d + \log(1/\delta)}{\epsilon^2}\right).$$

所以，下面的主线会完整展示从 Hoeffding 不等式到基础 VC 泛化界的推导；最后再说明为什么常见教材或讲义中会把样本复杂度简写为你图中的最优量级。

2 问题设定：二分类与 0-1 损失

设输入空间为 $\mathcal{X}$ ，标签空间为 $\{0, 1\}$ 。样本

$$S = \{(X_i, Y_i)\}_{i=1}^n$$

独立同分布地来自未知分布 $\mathcal{D}$ 。

假设空间为 $\mathcal{H}$ ，其中每个假设 $h \in \mathcal{H}$ 是一个二分类器：

$$h: \mathcal{X} \rightarrow \{0, 1\}.$$

对任意 $h \in \mathcal{H}$ ，定义真实风险：

$$R(h) = \mathbb{P}_{(X,Y) \sim \mathcal{D}}(h(X) \neq Y).$$

定义经验风险：

$$\hat{R}_S(h) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}\{h(X_i) \neq Y_i\}.$$

其中

$$\mathbf{1}\{h(X_i) \neq Y_i\} = \begin{cases} 1, & h(X_i) \neq Y_i, \\ 0, & h(X_i) = Y_i. \end{cases}$$

因此 $\hat{R}_S(h)$ 是 n 个 0-1 随机变量的平均值，而 $R(h)$ 是它们的期望。

2.1 我们想证明什么？

统计学习理论中的一个核心目标是证明**统一收敛**：

$$\sup_{h \in \mathcal{H}} \left| \widehat{R}_S(h) - R(h) \right|$$

随样本量 n 增大而变小。

如果能够证明以至少 $1 - \delta$ 的概率，

$$\sup_{h \in \mathcal{H}} \left| \widehat{R}_S(h) - R(h) \right| \leq \epsilon,$$

那么每个分类器的训练误差都能较好地代表真实误差。

3 第一步：固定一个分类器时，Hoeffding 不等式给出集中界

这里的 Hoeffding 不等式通常译为**霍夫丁不等式**。它说明：独立、有界随机变量的样本均值偏离其期望的概率会随 $n\epsilon^2$ 指数下降。

定理 3.1 (Hoeffding 不等式的 0-1 变量形式). 设 $Z_1, \dots, Z_n$ 独立同分布, 且 $Z_i \in [0, 1]$. 令

$$\bar{Z} = \frac{1}{n} \sum_{i=1}^n Z_i, \quad \mu = \mathbb{E}[Z_i].$$

则对任意 $\epsilon > 0$,

$$\mathbb{P}(|\bar{Z} - \mu| > \epsilon) \leq 2 \exp(-2n\epsilon^2).$$

对固定的 h , 令

$$Z_i = \mathbf{1}\{h(X_i) \neq Y_i\}.$$

那么

$$\bar{Z} = \widehat{R}_S(h), \quad \mu = R(h).$$

于是得到

$$\mathbb{P}\left(\left|\widehat{R}_S(h) - R(h)\right| > \epsilon\right) \leq 2 \exp(-2n\epsilon^2).$$

这一步只对一个**固定分类器**成立。

3.1 为什么会出现 ϵ^2 ？

因为 Hoeffding 不等式的指数项是

$$\exp(-2n\epsilon^2).$$

如果要想让失败概率变小，需要使

$$n\epsilon^2$$

足够大。等价地，若希望误差尺度达到 ϵ ，样本量通常要满足

$$n = O\left(\frac{1}{\epsilon^2}\right).$$

这就是样本复杂度里常见 $1/\epsilon^2$ 的来源。

4 第二步：有限假设空间，用 union bound 同时控制所有分类器

如果假设空间 $\mathcal{H}$ 是有限的，设

$$|\mathcal{H}| = M.$$

我们希望控制坏事件：

$$\exists h \in \mathcal{H} : \left| \hat{R}_S(h) - R(h) \right| > \epsilon.$$

对每个固定 h ，Hoeffding 不等式给出

$$\mathbb{P}\left(\left| \hat{R}_S(h) - R(h) \right| > \epsilon\right) \leq 2e^{-2n\epsilon^2}.$$

使用 union bound，中文叫并合界或联合界，即

$$\mathbb{P}\left(\bigcup_i A_i\right) \leq \sum_i \mathbb{P}(A_i).$$

因此

$$\begin{aligned} \mathbb{P}\left(\exists h \in \mathcal{H} : \left| \hat{R}_S(h) - R(h) \right| > \epsilon\right) \\ \leq \sum_{h \in \mathcal{H}} \mathbb{P}\left(\left| \hat{R}_S(h) - R(h) \right| > \epsilon\right) \\ \leq 2Me^{-2n\epsilon^2}. \end{aligned}$$

等价地，

$$\mathbb{P}\left(\sup_{h \in \mathcal{H}} \left| \hat{R}_S(h) - R(h) \right| > \epsilon\right) \leq 2|\mathcal{H}|e^{-2n\epsilon^2}.$$

如果希望右边不超过 δ ，令

$$2|\mathcal{H}|e^{-2n\epsilon^2} \leq \delta.$$

取对数：

$$\log 2 + \log |\mathcal{H}| - 2n\epsilon^2 \leq \log \delta.$$

整理得

$$n \geq \frac{\log(2|\mathcal{H}|) + \log(1/\delta)}{2\epsilon^2}.$$

所以对于有限假设空间，有

$$n = O\left(\frac{\log |\mathcal{H}| + \log(1/\delta)}{\epsilon^2}\right)$$

即可保证统一泛化误差不超过 ϵ 。

5 第三步：无限假设空间不能直接使用 $|\mathcal{H}|$

许多重要假设空间是无限的。例如线性分类器

$$h_{w,b}(x) = \mathbf{1}\{w^\top x + b \geq 0\}$$

中的参数 w, b 是连续值，所以 $|\mathcal{H}|$ 是无限的。

但是在 n 个固定样本点上，一个假设空间最多只能产生有限种标签模式。例如在点 $x_1, \dots, x_n$ 上，分类器 h 只产生一个 0-1 向量：

$$(h(x_1), \dots, h(x_n)) \in \{0, 1\}^n.$$

最多只有 2^n 种。

这启发我们不再数 $|\mathcal{H}|$ ，而是数 $\mathcal{H}$ 在有限样本上的**有效标记能力**。

定义 5.1 (增长函数). 假设空间 $\mathcal{H}$ 的增长函数定义为

$$\Pi_{\mathcal{H}}(m) = \max_{x_1, \dots, x_m \in \mathcal{X}} |\{(h(x_1), \dots, h(x_m)) : h \in \mathcal{H}\}|.$$

它表示：在任意 m 个点上， $\mathcal{H}$ 最多能实现多少种不同的 0-1 标记方式。

显然有

$$\Pi_{\mathcal{H}}(m) \leq 2^m.$$

但如果 $\mathcal{H}$ 的 VC 维有限，则可以得到远小于 2^m 的上界。

6 第四步：对称化，把真实风险换成两个经验风险之差

直接对无限 $\mathcal{H}$ 使用 union bound 很困难，因为 $R(h)$ 是对未知分布的期望，不只依赖样本上的标记。

VC 证明中常用一个技巧：**symmetrization**，**对称化**。它的作用是把

$$R(h) - \hat{R}_S(h)$$

这种“总体期望 - 样本均值”的差，转化为两个独立样本经验均值之间的差。

引入一份独立的 ghost sample (幽灵样本):

$$S' = \{(X'_i, Y'_i)\}_{i=1}^n,$$

它与 S 独立, 且同样来自 $\mathcal{D}$ 。

记

$$\hat{R}_{S'}(h) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}\{h(X'_i) \neq Y'_i\}.$$

直觉上, 因为

$$\mathbb{E}_{S'}[\hat{R}_{S'}(h)] = R(h),$$

所以可以把 $R(h)$ 看成另一份样本误差 $\hat{R}_{S'}(h)$ 的平均行为。

标准对称化结论可以写成如下形式:

$$\mathbb{P}_S \left(\sup_{h \in \mathcal{H}} |R(h) - \hat{R}_S(h)| > \epsilon \right) \leq 2\mathbb{P}_{S,S'} \left(\sup_{h \in \mathcal{H}} |\hat{R}_{S'}(h) - \hat{R}_S(h)| > \frac{\epsilon}{2} \right),$$

在常数条件下成立; 不同教材中的常数可能略有差异。

这一步非常关键:

- 左边涉及未知的真实分布 $\mathcal{D}$;
- 右边只涉及两个有限样本 S 和 S' ;
- 因此右边可以用增长函数来计数。

7 第五步: 在 $2n$ 个点上计数, 再使用 Hoeffding

现在固定两份样本 S, S' , 一共涉及 $2n$ 个输入点。

对任意 $h \in \mathcal{H}$, 它在这 $2n$ 个点上的预测模式最多只有

$$\Pi_{\mathcal{H}}(2n)$$

种。

因此, 我们可以把无限假设空间上的控制, 转化为对不超过 $\Pi_{\mathcal{H}}(2n)$ 个不同标记模式做 union bound。

对于某个固定标记模式,

$$\hat{R}_{S'}(h) - \hat{R}_S(h)$$

是两个经验平均值之差。继续使用 Hoeffding 类型的有界变量集中不等式, 可以得到类似

$$\mathbb{P} \left(|\hat{R}_{S'}(h) - \hat{R}_S(h)| > \frac{\epsilon}{2} \right) \leq 2 \exp \left(-\frac{n\epsilon^2}{8} \right).$$

再对所有可能的标记模式做 union bound, 就得到

$$\mathbb{P}_{S,S'} \left(\sup_{h \in \mathcal{H}} |\hat{R}_{S'}(h) - \hat{R}_S(h)| > \frac{\epsilon}{2} \right) \leq 2\Pi_{\mathcal{H}}(2n) \exp \left(-\frac{n\epsilon^2}{8} \right).$$

结合对称化前面的常数，得到基础 VC 不等式的一种常见形式：

$$\mathbb{P} \left(\sup_{h \in \mathcal{H}} |R(h) - \hat{R}_S(h)| > \epsilon \right) \leq 4\Pi_{\mathcal{H}}(2n) \exp \left(-\frac{n\epsilon^2}{8} \right)$$

这就是从 Hoeffding 不等式走向 VC 泛化界的核心桥梁。

8 第六步：用 VC 维控制增长函数

定义 8.1 (VC 维). 如果存在 d 个点，使得 $\mathcal{H}$ 能实现这 d 个点上的全部 2^d 种二分类标记，则称 $\mathcal{H}$ 可以打散这 d 个点。

假设空间 $\mathcal{H}$ 的 VC 维是它能够打散的最大点集大小，记为

$$\text{VCdim}(\mathcal{H}) = d.$$

如果 VC 维为 d ，则 $\mathcal{H}$ 不能打散任意 $d+1$ 个点。Sauer-Shelah 引理给出增长函数的组合上界。

引理 8.2 (Sauer-Shelah 引理). 若 $\text{VCdim}(\mathcal{H}) = d$ ，则对任意 $m \geq d$ ，

$$\Pi_{\mathcal{H}}(m) \leq \sum_{i=0}^d \binom{m}{i} \leq \left(\frac{em}{d} \right)^d.$$

令 $m = 2n$ ，得到

$$\Pi_{\mathcal{H}}(2n) \leq \left(\frac{2en}{d} \right)^d.$$

代入上一节的基础 VC 不等式：

$$\mathbb{P} \left(\sup_{h \in \mathcal{H}} |R(h) - \hat{R}_S(h)| > \epsilon \right) \leq 4 \left(\frac{2en}{d} \right)^d \exp \left(-\frac{n\epsilon^2}{8} \right).$$

这就是一个经典 VC 泛化界。

$$\mathbb{P} \left(\sup_{h \in \mathcal{H}} |R(h) - \hat{R}_S(h)| > \epsilon \right) \leq 4 \left(\frac{2en}{d} \right)^d \exp \left(-\frac{n\epsilon^2}{8} \right)$$

从结构上看，它由两部分组成：

$$\underbrace{\left(\frac{2en}{d} \right)^d}_{\text{模型复杂度}} \times \underbrace{\exp \left(-\frac{n\epsilon^2}{8} \right)}_{\text{集中项}}.$$

当样本量 n 增加时，集中项指数下降；当 VC 维 d 增大时，复杂度项上升。

9 第七步：由 VC 泛化界解出样本复杂度

希望以至少 $1 - \delta$ 的概率保证

$$\sup_{h \in \mathcal{H}} |R(h) - \hat{R}_S(h)| \leq \epsilon.$$

只需要令失败概率上界不超过 δ :

$$4 \left(\frac{2en}{d} \right)^d \exp \left(-\frac{n\epsilon^2}{8} \right) \leq \delta.$$

取对数:

$$\log 4 + d \log \left(\frac{2en}{d} \right) - \frac{n\epsilon^2}{8} \leq \log \delta.$$

整理:

$$\frac{n\epsilon^2}{8} \geq d \log \left(\frac{2en}{d} \right) + \log \frac{4}{\delta}.$$

即

$$n \geq \frac{8}{\epsilon^2} \left[d \log \left(\frac{2en}{d} \right) + \log \frac{4}{\delta} \right]$$

这是一个隐式不等式，因为右侧仍含有 n 。在样本复杂度记号中，它通常写成

$$n = O \left(\frac{d \log(1/\epsilon) + \log(1/\delta)}{\epsilon^2} \right)$$

这就是由 Hoeffding 不等式、对称化、增长函数和 Sauer-Shelah 引理得到的基础 VC 样本复杂度。

10 第八步：如何理解更简洁的 $O((d + \log(1/\delta))/\epsilon^2)$?

你图中的公式为

$$n = O \left(\frac{d + \log(1/\delta)}{\epsilon^2} \right)$$

它是更精细理论下的最优量级。与上一节的基础推导相比，它少了一个 $d \log(1/\epsilon)$ 因子。

更准确地说:

- Hoeffding + union bound 的直接路径，天然会出现“要同时控制多少种标记模式”的计数项;
- 用 Sauer-Shelah 引理控制计数项时，通常留下 $d \log n$ 或 $d \log(1/\epsilon)$;

- 更精细的 VC 理论不是简单把这个项“忽略掉”，而是通过更紧的随机过程分析证明：二分类 VC 类的泛化偏差本质尺度是

$$O\left(\sqrt{\frac{d + \log(1/\delta)}{n}}\right).$$

如果有

$$\sup_{h \in \mathcal{H}} |R(h) - \hat{R}_S(h)| \leq C \sqrt{\frac{d + \log(1/\delta)}{n}},$$

令右边不超过 ϵ ，就得到

$$C \sqrt{\frac{d + \log(1/\delta)}{n}} \leq \epsilon.$$

两边平方：

$$\frac{C^2(d + \log(1/\delta))}{n} \leq \epsilon^2.$$

整理得

$$n \geq C^2 \frac{d + \log(1/\delta)}{\epsilon^2}.$$

用大 O 记号写就是

$$n = O\left(\frac{d + \log(1/\delta)}{\epsilon^2}\right).$$

因此，你图里的公式可以理解为：

它不是最朴素 Hoeffding-union-bound 推导的直接形式，而是 VC 类二分类问题的更紧、最优量级表达。朴素推导给出正确直觉和基础界；精细理论去掉了多余的 $\log(1/\epsilon)$ 。

11 ERM 的泛化含义：训练误差小为什么能推出真实误差小？

设经验风险最小化算法 ERM 选择

$$\hat{h} \in \arg \min_{h \in \mathcal{H}} \hat{R}_S(h).$$

如果统一收敛成立，即对所有 $h \in \mathcal{H}$ ，

$$|R(h) - \hat{R}_S(h)| \leq \epsilon,$$

那么令

$$h^* \in \arg \min_{h \in \mathcal{H}} R(h),$$

有

$$\begin{aligned} R(\hat{h}) &\leq \hat{R}_S(\hat{h}) + \epsilon \\ &\leq \hat{R}_S(h^*) + \epsilon \\ &\leq R(h^*) + 2\epsilon. \end{aligned}$$

也就是说, ERM 的真实风险最多比假设空间中的最优真实风险多 2ϵ 。这说明统一泛化界不仅控制每个模型的训练误差和真实误差差距, 也能解释为什么经验风险最小化能够泛化。

12 常见误区总结

误区	更准确的说法
把 $ \mathcal{H} $ 直接替换成 2^d	VC 维 d 不表示假设空间只有 2^d 个分类器; 它通过 Sauer-Shelah 引理控制增长函数 $\Pi_{\mathcal{H}}(m)$ 。
认为 Hoeffding 直接推出 VC 界	Hoeffding 只控制固定 h ; 要得到 VC 界, 还需要 union bound、对称化、增长函数、Sauer-Shelah 引理。
认为 d 越大一定越坏	d 越大确实提高样本复杂度, 但如果数据量足够大, 更大的假设空间也可能带来更小的近似误差。泛化误差只是学习问题的一部分。
忽略 δ 的作用	δ 是失败概率。要求更高置信度, 即更小 δ , 会增加样本需求, 但只以 $\log(1/\delta)$ 速度增加。
把所有 VC 界都写成同一个公式	可实现情形、不可实现情形、统一收敛、ERM 超额风险、朴素界、最优界的样本复杂度可能不同。

13 完整推导链条回顾

1. 对固定 h , $\hat{R}_S(h)$ 是 0-1 随机变量的均值。Hoeffding 给出:

$$\mathbb{P}\left(|\hat{R}_S(h) - R(h)| > \epsilon\right) \leq 2e^{-2n\epsilon^2}.$$

2. 若 $\mathcal{H}$ 有限, union bound 给出:

$$\mathbb{P}\left(\sup_{h \in \mathcal{H}} |\hat{R}_S(h) - R(h)| > \epsilon\right) \leq 2|\mathcal{H}|e^{-2n\epsilon^2}.$$

3. 若 $\mathcal{H}$ 无限, 不能直接用 $|\mathcal{H}|$, 改用增长函数 $\Pi_{\mathcal{H}}(m)$ 。

4. 用对称化把真实风险与经验风险的差, 转化为两份样本经验风险的差:

$$\sup_h |R(h) - \hat{R}_S(h)| \rightsquigarrow \sup_h |\hat{R}_{S'}(h) - \hat{R}_S(h)|.$$

5. 在 $2n$ 个点上，最多有 $\Pi_{\mathcal{H}}(2n)$ 种标记模式，因此可以再次使用 union bound。

6. Sauer-Shelah 引理用 VC 维 d 控制增长函数：

$$\Pi_{\mathcal{H}}(2n) \leq \left(\frac{2en}{d}\right)^d.$$

7. 代入得到基础 VC 泛化界：

$$\mathbb{P}\left(\sup_{h \in \mathcal{H}} |R(h) - \hat{R}_S(h)| > \epsilon\right) \leq 4 \left(\frac{2en}{d}\right)^d \exp\left(-\frac{n\epsilon^2}{8}\right).$$

8. 解出样本复杂度，得到基础形式：

$$n = O\left(\frac{d \log(1/\epsilon) + \log(1/\delta)}{\epsilon^2}\right).$$

9. 更精细的 VC 理论可以把它改进为最优量级：

$$n = O\left(\frac{d + \log(1/\delta)}{\epsilon^2}\right).$$

附：经典来源

- Vapnik 与 Chervonenkis 在 1971 年发表于 *Theory of Probability and Its Applications* 的论文中系统提出了与 VC 维相关的统一收敛思想。
- Sauer 在 1972 年发表于 *Journal of Combinatorial Theory, Series A* 的论文，以及 Shelah 在 1972 年发表于 *Israel Journal of Mathematics* 的论文，给出了后来常称为 Sauer-Shelah 引理的组合计数上界。
- 更紧的去 $\log(1/\epsilon)$ 因子的结果通常属于更精细的经验过程、VC entropy、Rademacher complexity 或 packing/covering 分析范畴。