

从真实误差到“训练误差 + 复杂度惩罚”的推导

1 先说结论：它不是严格等式

常见说法

$$\text{真实误差} \approx \text{训练误差} + \text{复杂度惩罚}$$

更准确地说，是一个高概率上界：

$$R(h) \leq \hat{R}_S(h) + \text{复杂度惩罚项}.$$

它的意思是：模型在真实数据分布上的误差，通常不会比训练集误差大太多；多出来的部分由模型复杂度和样本量共同控制。

2 我们真正想最小化什么？

设真实数据来自未知分布 P ：

$$(x, y) \sim P.$$

模型记为 h ，损失函数记为 $\ell(h(x), y)$ 。真实风险，也叫泛化误差，定义为：

$$R(h) = \mathbb{E}_{(x, y) \sim P} [\ell(h(x), y)].$$

它表示模型在真实世界所有可能样本上的平均损失。

如果是分类任务，并使用 0-1 损失：

$$\ell(h(x), y) = \begin{cases} 0, & h(x) = y, \\ 1, & h(x) \neq y, \end{cases}$$

那么

$$R(h) = \Pr(h(x) \neq y),$$

即模型在真实数据分布上的分类错误率。

3 但真实风险 $R(h)$ 无法直接计算

因为真实分布 P 通常未知，我们手里只有训练集：

$$S = \{(x_1, y_1), \dots, (x_n, y_n)\}.$$

所以只能计算训练集上的平均损失：

$$\hat{R}_S(h) = \frac{1}{n} \sum_{i=1}^n \ell(h(x_i), y_i).$$

这叫经验风险，也可以理解为训练误差。

自然的想法是：

$$\hat{R}_S(h) \approx R(h).$$

也就是用训练误差估计真实误差。

4 问题：训练误差可能低估真实误差

如果模型在训练集上错误率很低，不代表它在真实数据上也一定低。比如：

模型	训练错误率	真实错误率
简单模型	10%	12%
复杂模型	0%	30%

复杂模型可能只是把训练集“背下来”了，这就是过拟合。因此不能只看 $\hat{R}_S(h)$ ，还要问：训练误差和真实误差之间最多可能差多少？也就是研究

$$R(h) - \hat{R}_S(h).$$

5 第一步：固定一个模型 h

先考虑一个固定模型 h ，不是从很多模型里挑出来的。令

$$Z_i = \ell(h(x_i), y_i).$$

如果使用 0-1 损失，则

$$Z_i \in \{0, 1\}.$$

于是经验风险就是

$$\hat{R}_S(h) = \frac{1}{n} \sum_{i=1}^n Z_i,$$

真实风险就是

$$R(h) = \mathbb{E}[Z_i].$$

所以问题变成：用 n 个样本的平均值估计总体期望，误差有多大？

根据 Hoeffding 不等式，即一种控制样本均值偏离真实期望的集中不等式，有：

$$\Pr(R(h) - \hat{R}_S(h) \geq \epsilon) \leq \exp(-2n\epsilon^2).$$

这里 $\Pr(\cdot)$ 表示事件发生的概率。上式中的“坏事件”是：

$$R(h) - \hat{R}_S(h) \geq \epsilon,$$

即训练误差严重低估真实误差。

如果希望失败概率不超过 δ ，令：

$$\exp(-2n\epsilon^2) = \delta.$$

两边取对数并整理：

$$-2n\epsilon^2 = \log \delta,$$

$$\epsilon^2 = \frac{\log(1/\delta)}{2n},$$

$$\epsilon = \sqrt{\frac{\log(1/\delta)}{2n}}.$$

于是，对于固定模型 h ，有：

$$R(h) \leq \hat{R}_S(h) + \sqrt{\frac{\log(1/\delta)}{2n}}.$$

这时还没有复杂度项，因为我们只看了一个固定模型。

6 第二步：为什么会出现模型复杂度？

机器学习通常不是提前固定一个模型，而是在很多候选模型里挑一个。设模型集合为

$$\mathcal{H} = \{h_1, h_2, \dots, h_M\}.$$

训练时经常选择训练误差较小的模型：

$$\hat{h} = \arg \min_{h \in \mathcal{H}} \hat{R}_S(h).$$

问题是：模型越多，越容易碰巧找到一个在训练集上表现很好、但真实表现很差的模型。

对单个模型有：

$$\Pr \left(R(h) - \hat{R}_S(h) \geq \epsilon \right) \leq \exp(-2n\epsilon^2).$$

对 M 个模型同时考虑，用联合界（union bound），即“多个坏事件中至少一个发生的概率不超过它们概率之和”：

$$\Pr \left(\exists h \in \mathcal{H} : R(h) - \hat{R}_S(h) \geq \epsilon \right) \leq |\mathcal{H}| \exp(-2n\epsilon^2).$$

令这个失败概率不超过 δ ：

$$|\mathcal{H}| \exp(-2n\epsilon^2) = \delta.$$

于是：

$$\begin{aligned} \exp(-2n\epsilon^2) &= \frac{\delta}{|\mathcal{H}|}, \\ -2n\epsilon^2 &= \log \delta - \log |\mathcal{H}|, \\ \epsilon^2 &= \frac{\log |\mathcal{H}| + \log(1/\delta)}{2n}, \\ \epsilon &= \sqrt{\frac{\log |\mathcal{H}| + \log(1/\delta)}{2n}}. \end{aligned}$$

因此，以至少 $1 - \delta$ 的概率，对所有 $h \in \mathcal{H}$ 都有：

$$R(h) \leq \hat{R}_S(h) + \sqrt{\frac{\log |\mathcal{H}| + \log(1/\delta)}{2n}}.$$

这就是最基础版本的：

$$\boxed{\text{真实误差} \leq \text{训练误差} + \text{复杂度惩罚}}$$

其中

$$\text{复杂度惩罚} = \sqrt{\frac{\log |\mathcal{H}| + \log(1/\delta)}{2n}}.$$

7 这个公式怎么理解？

可以把它看成一个权衡：

$$R(h) \lesssim \hat{R}_S(h) + O \left(\sqrt{\frac{\text{complexity}(\mathcal{H})}{n}} \right).$$

其中：

- $\hat{R}_S(h)$ 衡量模型有没有学好训练数据；
- 复杂度惩罚衡量模型有没有过度依赖训练数据；

- n 越大, 惩罚项越小;
- 模型类 $\mathcal{H}$ 越复杂, 惩罚项越大;
- 样本数的作用通常是 $1/\sqrt{n}$ 级别, 而不是 $1/n$ 级别。

例如:

模型类	训练错误率	复杂度惩罚	泛化上界
简单模型	8%	3%	11%
复杂模型	1%	20%	21%

复杂模型训练错误率更低, 但由于复杂度惩罚更大, 泛化上界反而可能更差。

8 为什么假设损失在 $[0, 1]$?

上面的 Hoeffding 不等式需要随机变量有界。若使用 0-1 损失, 则

$$\ell(h(x), y) \in \{0, 1\} \subset [0, 1],$$

因此可以直接使用最简单形式的 Hoeffding 不等式。

如果损失函数范围是 $[a, b]$, 则对应形式会变成:

$$\Pr\left(R(h) - \hat{R}_S(h) \geq \epsilon\right) \leq \exp\left(-\frac{2n\epsilon^2}{(b-a)^2}\right).$$

损失范围越大, 得到的上界越松。

如果损失无界, 例如交叉熵损失理论上可以趋近无穷大, 那么不能直接使用这个最简单的 Hoeffding 推导; 需要额外假设或使用其他集中不等式。

9 分类错误率是什么?

分类错误率就是模型分类错的样本比例:

$$\text{分类错误率} = \frac{\text{预测错误的样本数}}{\text{总样本数}}.$$

它对应 0-1 损失:

$$\ell(h(x), y) = \begin{cases} 0, & h(x) = y, \\ 1, & h(x) \neq y. \end{cases}$$

因此, 真实风险为:

$$R(h) = \Pr(h(x) \neq y),$$

经验风险为:

$$\hat{R}_S(h) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}[h(x_i) \neq y_i].$$

10 最后总结

完整逻辑链是：

我们想最小化真实误差 $R(h)$,

但 $R(h)$ 不能直接计算，所以用训练误差 $\hat{R}_S(h)$ 来估计。训练误差可能低估真实误差，尤其是在模型类很复杂时。因此需要用集中不等式控制

$$R(h) - \hat{R}_S(h).$$

对于有限模型类 $\mathcal{H}$ ，最终得到：

$$R(h) \leq \hat{R}_S(h) + \sqrt{\frac{\log |\mathcal{H}| + \log(1/\delta)}{2n}}$$

以至少 $1 - \delta$ 的概率成立。

所以“真实误差 = 训练误差 + 复杂度惩罚”的准确含义是：

真实误差通常可以被训练误差加上一个复杂度惩罚项控制住。

它不是严格等式，而是泛化理论中的高概率上界思想。